

Analisi di dati sperimentali sulla produzione di biomassa

Giorgia Caicchiolo, Marco Nascimben, Riccardo Pati, Luca Varotto

June 8 2026

1 Introduzione

La produzione di biomassa da cianobatteri rappresenta un tema di interesse in diversi ambiti applicativi, tra cui la bioenergia, la produzione di composti ad alto valore aggiunto e i processi di economia circolare. In questo contesto, comprendere l'effetto delle condizioni di coltivazione sulla dinamica di crescita della biomassa è fondamentale per individuare configurazioni operative efficienti e riproducibili. Dal punto di vista biologico, la crescita della biomassa è attesa seguire un andamento non lineare, caratterizzato da una fase iniziale di crescita accelerata e da un successivo rallentamento verso un livello massimo di produzione.

Il presente studio analizza un esperimento condotto su una coltura di *textitNostoc* in condizioni controllate, nel quale la resa di biomassa, misurata tramite *Densità Ottica* (OD), è stata osservata nel corso di 8 settimane sotto differenti combinazioni di *Intensità luminosa* (I), *Durata dell'esposizione alla luce* (D) e *Concentrazione di fosforo* (P). L'obiettivo dell'analisi è duplice: descrivere quantitativamente l'evoluzione temporale della biomassa e valutare come le condizioni sperimentali influenzino sia la resa massima raggiungibile sia la rapidità con cui essa viene ottenuta.

2 Il disegno sperimentale

La regione di interesse sperimentale è definita da un dominio cubico tridimensionale. Per l'esplorazione dello spazio dei fattori non è stato impiegato un disegno fattoriale completo a tre livelli ($3^3 = 27$ combinazioni), bensì una configurazione ispirata alla struttura di un disegno composito centrale a facce centrate (*Face-Centered Central Composite Design*, FCCCD, Figura 1) [1].




Figura 1: Rappresentazione grafica di un FCCCD da [2]. Ogni asse rappresenta un fattore sperimentale.

Rispetto a un FCCCD classico, che prevede 15 combinazioni uniche (8 punti fattoriali ai vertici, il punto centrale e 6 punti assiali al centro delle facce), il disegno in esame presenta due combinazioni geometriche aggiuntive: $I = 90$, $D = 24$, $P = 25.50$ e $I = 470$, $D = 24$, $P = 25.50$, per un totale di 17 combinazioni sperimentali distinte.

Il disegno presenta una struttura di replicazione non uniforme tra i diversi punti sperimentali: 16 combinazioni presentano un numero di repliche variabile tra 2 e 4, mentre la 17esima combinazione, corrispondente al punto centrale del disegno

($I = 280$, $D = 18$, $P = 25.50$), conta 8 repliche. Questa forte iper-replicazione del punto centrale è standard nella metodologia delle superfici di risposta, in quanto garantisce una stima robusta della varianza dell'errore sperimentale (errore puro) e una maggiore uniformità della varianza della risposta prevista all'interno del dominio. La distribuzione delle repliche è schematizzata in Figura 2.




Figura 2: Rappresentazione della numerosità di ogni combinazione dei tre fattori.

I disegni FCCCD nascono storicamente nell'ambito della *Response Surface Methodology* (RSM). Sotto questo paradigma, si assume che la variabile di risposta sia uno scalare e che possa essere modellata come una funzione polinomiale di secondo grado rispetto alle covariate, intercettando così curvature ed effetti di interazione [1]. Nel caso in esame, tuttavia, la risposta è una serie storica e non un singolo valore. Di conseguenza, questo specifico assunto teorico non è direttamente applicabile ai dati grezzi e l'impianto RSM classico non può essere implementato nella sua forma canonica.

Nonostante questo limite, la geometria del FCCCD è comunque utile perché garantisce una copertura ottimale dello spazio sperimentale. Anche se non abbiamo una risposta scalare, ha comunque senso verificare se i tre fattori (I , D , P) hanno un effetto quadratico sulle curve di crescita, permettendo così di catturare effetti più complessi.

3 Analisi Esplorativa

Le 53 biomasse monitorate presentano complessivamente 371 osservazioni, di cui 2 mancanti: entrambe corrispondono all'ultima settimana di rilevazione e appartengono alla stessa condizione sperimentale ($I = 90$, $D = 24$), sebbene con concentrazioni di fosforo diverse ($P = 1$ e $P = 25.5$). Poiché il dato mancante non è distribuito in modo uniforme sulle condizioni sperimentali, l'ipotesi di missingness completamente casuale (MCAR) non è sostenibile; è più plausibile un meccanismo MAR, in cui la probabilità di osservazione mancante dipende dai valori dei fattori registrati. Le traiettorie delle due unità interessate, visualizzate in Figura 3, non mostrano anomalie fino all'ultima rilevazione disponibile, confermando che l'assenza è verosimilmente imputabile a ragioni sperimentali esterne alla dinamica biologica.

In Figura 4 si riportano tutte le curve osservate. Si identifica un'unità con un'evoluzione marcatamente anomala rispetto alle altre: dopo verifica, tale profilo non è stato attribuito a un errore di misura e si è deciso di mantenerlo nell'analisi.

Come illustrato nella Sezione 2, il disegno sperimentale prevede 17 combinazioni distinte dei fattori I , D e P . In Figura 5 si confrontano le singole traiettorie con le curve medie per ciascuna condizione: la variabilità intra-condizione risulta contenuta per la maggior parte delle combinazioni, a eccezione di alcune condizioni con repliche più eterogenee.

Al fine di valutare l'effetto marginale di ciascun fattore, in Figura 6 le curve sono colorate in base ai livelli di I , D e P separatamente. Si osserva un effetto apprezzabile dell'intensità luminosa I : le biomasse esposte a $I = 470$ mostrano una resa finale sistematicamente superiore rispetto a quelle con $I = 90$. L'effetto marginale di D e P appare meno marcato a livello visivo.

Per esaminare le possibili interazioni tra fattori, in Figura 7 si riportano i grafici delle dinamiche medie condizionate: si fissa un fattore come variabile di pannello e si colorano le curve medie per i livelli di un secondo fattore. Dal confronto emerge




Figura 3: A sinistra: traiettorie delle due unità con dato mancante all'ultima settimana, colorate per condizione sperimentale. A destra: le stesse unità (in arancione) evidenziate nel contesto di tutte le 53 curve.

un'interazione tra l'intensità luminosa I e la durata dell'esposizione D : a parità di I , una durata prolungata ($D = 24$) tende ad amplificare l'effetto positivo dell'intensità elevata sulla resa finale. L'effetto del fosforo P appare invece più uniforme tra i pannelli.

Successivamente, si è analizzato il comportamento degli incrementi temporali. In Figura 8 si riportano gli incrementi assoluti $\Delta OD_t = OD_t - OD_{t-1}$ e i rapporti $\frac{OD_t}{OD_{t-1}}$, colorati per condizione sperimentale. Entrambe le rappresentazioni evidenziano un andamento decrescente nelle settimane finali: gli incrementi tendono a zero e i rapporti si avvicinano a 1, segnalando un rallentamento della crescita. Tale segnale è coerente con l'assunzione di un asintoto, sebbene l'orizzonte temporale di 8 settimane non sia sufficiente a osservare un plateau completo nelle osservazioni in scala originale; questo costituisce una limitazione del disegno che andrà considerata nella fase di modellazione.

Infine, è stata analizzata l'evoluzione della varianza dei dati di OD in funzione del tempo e della media empirica. Come mostrato nel grafico a sinistra della Figura 9, la varianza non è costante, ma aumenta in modo non lineare con il progredire del tempo. Il grafico a destra evidenzia la relazione diretta tra media e varianza calcolate per ciascun punto temporale: la varianza si configura come una funzione non lineare e crescente della media. Questo fenomeno di eteroschedasticità (nello specifico, iperdispersione rispetto al modello teorico di Poisson rappresentato dalla retta tratteggiata) è coerente con la natura dei processi biologici, in cui la variabilità stocastica tende ad amplificarsi all'aumentare dell'intensità del segnale.

4 Struttura e formulazione del modello statistico

4.1 La componente di media

Dall'analisi esplorativa è emerso chiaramente come la crescita di ciascuna biomassa abbia un comportamento non lineare (Figura 4 e Figura 5). Questo comportamento è tipico delle meccaniche di crescita in un contesto ecologico [3], ma anche per lo specifico batterio *Nostoc* [4].

Per descrivere tale evoluzione abbiamo assunto che la media della curva di crescita segua la funzione di Gompertz, questa scelta è altrettanto comune in questo contesto. Questa funzione descrive una fase iniziale di rapida espansione, seguita da un progressivo rallentamento fino al raggiungimento di un asintoto. Tale impostazione è coerente con le curve degli incrementi osservate, caratterizzate da una velocità di crescita dapprima in aumento ma che poi cala, ad indicare che si sta raggiungendo l'asintoto superiore. Inoltre, i dati osservati non evidenziano una fase di declino successiva al raggiungimento di un plateau, perciò si è scelto di non adottare modelli in grado di catturare dinamiche decrescenti. È stata considerata una conveniente riparametrizzazione della funzione di Gompertz, che viene regolata dai parametri $Asym$, b_2 , b_3 , che spiegano rispettivamente asintoto, inizio della crescita e velocità di crescita. I parametri di interesse, in particolare, risultano essere l'asintoto e la velocità di crescita.




Figura 4: Traiettorie di OD per tutte le 53 biomasse colorate per condizione sperimentale. Si nota un'unità con comportamento anomalo (crescita marcatamente più rapida rispetto alle restanti), mantenuta nell'analisi.

4.2 Correlazione

La presenza di misurazioni ripetute sullo stesso soggetto nel tempo può presentare correlazione seriale. Per tenere conto di questa possibile struttura di correlazione, descritta mediante una struttura autoregressiva del primo ordine (AR(1)).

4.3 Eteroschedasticità

La varianza inoltre risulta essere non costante lungo tutto il processo di crescita, configurando una situazione di eteroschedasticità; in particolare, si osserva come aumenti al passare del tempo e al crescere della media della variabile risposta.

4.4 Effetto casuale

Per tenere conto della correlazione presente nei dati longitudinali e delle misure ripetute su osservazioni appartenenti allo stesso disegno sperimentale sono stati considerati nel modello degli effetti casuali (RE) sui parametri di interesse, cioè l'asintoto e la velocità di crescita.

La scelta della struttura di variabilità e degli effetti casuali è stata effettuata tramite criteri di informazione e analisi dell'adattamento delle curve previste.

5 Il Modello Bayesiano

Sia $Y_i = (Y_{i1}, \dots, Y_{in_i})^T$ il vettore delle misurazioni di OD per l'unità campionaria i -esima, con $n_i = 6$ per $i \in \{12, 15\}$ e $n_i = 7$ per $i \in \{1, \dots, 53\} \setminus \{12, 15\}$. Il modello assume che il vettore delle risposte segua una distribuzione normale multivariata:

$$Y_i \sim N_{n_i}(\mu_i(\theta_i), V_i), \quad i = 1, \dots, 53$$

dove $\mu_i(\theta_i)$ è il vettore dei valori attesi ai tempi di misurazione $t = (t_{i1}, \dots, t_{in_i})^T$ e V_i è la matrice di covarianza. Assumendo indipendenza condizionata tra le misurazioni longitudinali della stessa unità dato l'effetto casuale, la matrice V_i è diagonale. Per gestire l'eteroschedasticità, la varianza marginale segue una funzione di potenza (*power-law*) della media:




Figura 5: Curve medie per condizione (repliche in grigio sullo sfondo; la banda rappresenta ± 1 errore standard della media).




Figura 6: Curve di crescita colorate per livello di ciascun fattore: intensità luminosa I (sinistra), durata D (centro), concentrazione di fosforo P (destra). Le curve in grassetto rappresentano le medie per livello; le bande indicano ± 1 errore standard.

$$V_i = \sigma^2 \text{diag}(\mu_{i1}^\delta, \dots, \mu_{in_i}^\delta)$$

La funzione media non lineare si basa sulla parametrizzazione biologica di Gompertz. Per la singola osservazione al tempo t_{ij} , il valore atteso è definito come:

$$\mu_{ij} = A_i \exp(-B_i C_i^{t_{ij}})$$

I parametri strutturali specifici per l'unità i -esima, $\theta_i = (A_i, B_i, C_i)^T$, rappresentano rispettivamente l'asintoto, il parametro di traslazione e il tasso di crescita. Essendo grandezze strettamente positive (con C_i vincolato in $(0, 1)$ per garantire la finitezza dell'asintoto), sono mappati sul predittore lineare tramite le funzioni legame logaritmica e logit.

Sia x_i il vettore contenente i 10 termini del predittore sperimentale (l'intercetta, i termini lineari I, D, P , le interazioni a due vie $I \cdot D, I \cdot P, D \cdot P$ e i termini quadratici I^2, D^2, P^2). La struttura gerarchica dei parametri è la seguente:

$$\begin{aligned}\log(A_i) &= x_i^T \beta_A \\ \log(B_i) &= x_i^T \beta_B \\ \text{logit}(C_i) &= x_i^T \beta_C + v_i\end{aligned}$$

L'eterogeneità biologica latente nel tasso di crescita è modellata tramite l'effetto casuale v_i , per il quale si assume:

$$v_i \sim N(0, \sigma_C^2)$$

Il modello è completato dall'assegnazione delle distribuzioni a priori. Per le intercette dei predittori lineari, indicate con $\beta_{k,1}$ con $k \in \{A, B, C\}$, adottiamo le seguenti a priori:

$$\begin{aligned}\beta_{A,1} &\sim N(2.1, 0.2^2) \\ \beta_{B,1} &\sim N(0.7, 0.5^2) \\ \beta_{C,1} &\sim N(0.5, 0.5^2)\end{aligned}$$

mentre sui coefficienti delle covariate, indicati con $\beta_{k,m}$ con $m \in \{2, \dots, 10\}$, si ha:

$$\beta_{k,m} \sim N(0, 0.25^2) \quad \forall k \in \{A, B, C\}, m \in \{2, \dots, 10\}$$

Infine, le priori per le componenti di varianza e per il parametro di scala *power-law* sono:

$$\begin{aligned}\sigma_C &\sim \text{Exp}(1) \\ \sigma &\sim \text{Exp}(1) \\ \delta &\propto N(1, 0.5^2) I(\delta > 0)\end{aligned}$$

6 Adattamento

LPPD = log predicted posterior density. Sfrutta la disuguaglianza di jensen per fare una LOOCV al contrario
WAIC per confronto tra modelli

7 Inferenza

8 Conclusioni

Bibliografia

- [1] Douglas C Montgomery. *Design and analysis of experiments*. John wiley & sons, 2013.
- [2] Rainer Lach et al. *DoE Application within Analytical Valve Train Development*. 2005. ISBN: 978-3816924982.
- [3] CE Timothy Paine et al. “How to fit nonlinear plant growth models and calculate growth rates: an update for ecologists”. In: *Methods in Ecology and Evolution* 3.2 (2012), pp. 245–256.
- [4] Martha Lucia Ortiz-Moreno et al. “Modeling the effects of light wavelength on the growth of *Nostoc ellipsosporum*”. In: *Universitas Scientiarum* 25.1 (2020), pp. 113–148.




Figura 7: Dinamiche di crescita medie condizionate. Dall'alto: (1) curve medie per livello di D , con pannelli separati per I ; (2) curve medie per livello di D , con pannelli separati per P ; (3) curve medie per livello di P , con pannelli separati per I . Le




Figura 8: Incrementi temporali di OD colorati per consumo $C = I \cdot D$. A sinistra: differenze assolute ΔOD ; la linea tratteggiata rossa indica il valore zero. A destra: rapporti OD_t / OD_{t-1} ; la linea tratteggiata rossa indica il valore 1. Le curve in grassetto sono le medie per livello di consumo; le bande indicano ± 1 errore standard.




Figura 9: Analisi della variabilità dei dati di OD. A sinistra: andamento della varianza in funzione del tempo. A destra: relazione tra media e varianza per ciascun punto temporale; la linea grigia tratteggiata rappresenta la relazione lineare. In entrambi i grafici, la linea rossa indica il trend non parametrico stimato mediante regressione locale LOESS (span = 1).