

Analisi di dati sperimentali sulla produzione di biomassa

Giorgia Caicchiolo, Marco Nascimben, Riccardo Pati, Luca Varotto

8 Giugno 2026

1 Introduzione

La produzione di biomassa da cianobatteri rappresenta un tema di interesse in diversi ambiti applicativi, tra cui la bioenergia, la produzione di composti ad alto valore aggiunto e i processi di economia circolare. In questo contesto, comprendere l'effetto delle condizioni di coltivazione sulla dinamica di crescita della biomassa è fondamentale per individuare configurazioni operative efficienti e riproducibili. Dal punto di vista biologico, la crescita della biomassa è attesa seguire un andamento non lineare, caratterizzato da una fase iniziale di crescita accelerata, da un successivo rallentamento verso un livello massimo di produzione, e da un'eventuale fase di riduzione.

Il presente studio analizza un esperimento condotto su una coltura di *Nostoc* in condizioni controllate, nel quale la resa di biomassa, misurata tramite *Densità Ottica* (OD), è stata osservata nel corso di 8 settimane sotto differenti combinazioni di *Intensità luminosa* (I), *Durata dell'esposizione alla luce* (D) e *Concentrazione di fosforo* (P). Sebbene il valore iniziale della variabile risposta sia ignoto, sappiamo essere analogo per tutte le unità sperimentali. L'obiettivo dell'analisi è duplice: descrivere quantitativamente l'evoluzione temporale della biomassa e valutare come le condizioni sperimentali influenzino sia la resa massima raggiungibile sia la rapidità con cui essa viene ottenuta.

2 Il disegno sperimentale

La regione di interesse sperimentale è definita da un dominio cubico tridimensionale. Per l'esplorazione dello spazio dei fattori non è stato impiegato un disegno fattoriale completo a tre livelli ($3^3 = 27$ combinazioni), bensì una configurazione ispirata alla struttura di un disegno composito centrale a facce centrate (*Face-Centered Central Composite Design*, FCCCD, Figura 1) [1]. Rispetto a un FCCCD classico, che prevede 15 combinazioni uniche (8 punti fattoriali ai vertici, il punto centrale e 6 punti assiali al centro delle facce), il disegno in esame presenta due combinazioni geometriche aggiuntive: $I = 90$, $D = 24$, $P = 25.50$ e $I = 470$, $D = 24$, $P = 25.50$, per un totale di 17 combinazioni sperimentali distinte.






Figura 1: Rappresentazione grafica di un FCCCD da [2]. Ogni asse rappresenta un fattore sperimentale.

Il disegno presenta una struttura di replicazione non uniforme tra i diversi punti sperimentali: 16 combinazioni presentano un numero di repliche variabile tra 2 e 4, mentre la 17esima combinazione, corrispondente al punto centrale del disegno ($I = 280$, $D = 18$, $P = 25.50$), conta 8 repliche. Questa forte iper-replicazione del punto centrale è standard nella *Response Surface Methodology*, in quanto garantisce una stima robusta della varianza dell'errore sperimentale e una maggiore uniformità della varianza della risposta prevista all'interno del dominio. La distribuzione delle repliche è schematizzata in Figura 2b. I disegni FCCCD nascono storicamente nell'ambito della *Response Surface Methodology* (RSM). Sotto questo paradigma, si assume che la variabile di risposta sia uno scalare e che possa essere modellata come una funzione polinomiale di secondo



(a) Rappresentazione 3D del disegno sperimentale.



(b) Rappresentazione della numerosità di ogni combinazione dei tre fattori.

Figura 2: Rappresentazione grafica del disegno sperimentale.


grado rispetto alle covariate, intercettando così curvature ed effetti di interazione [1]. Nel caso in esame, tuttavia, la risposta è una serie storica e non un singolo valore. Di conseguenza, questo assunto non è direttamente applicabile ai dati grezzi e l'impianto RSM classico non può essere implementato nella sua forma canonica. Nonostante questo limite, la geometria del FCCCD rimane fondamentale perché garantisce una copertura ottimale dello spazio sperimentale. Anche in assenza di una risposta scalare, testare l'effetto quadratico dei fattori (I , D , P) sulle curve di crescita è una scelta metodologica cruciale poiché permette di stimare un paraboloide, in grado di identificare un punto di massimo non solo sul bordo del dominio sperimentale, ma anche al suo interno. Questo approccio consente di catturare andamenti biologici più complessi, come l'esistenza di punti di saturazione, che un modello con soli effetti lineari non sarebbe in grado di individuare.

3 Analisi Esplorativa


In Figura 3a si riportano tutte le curve osservate, colorate per condizione sperimentale; in Figura 3b si confrontano le singole traiettorie con le curve medie per ciascuna condizione: come illustrato nella Sezione 2, il disegno sperimentale prevede 17 combinazioni distinte dei fattori I , D e P . La variabilità intra-condizione risulta contenuta per la maggior parte delle combinazioni, a eccezione di alcune condizioni con repliche più eterogenee. È stata osservata un'unità con un'evoluzione anomala rispetto alle altre: dopo verifica, tale profilo non è stato attribuito a un errore di misura e si è deciso di mantenerlo nell'analisi. Le 53 biomasse monitorate presentano complessivamente 371 osservazioni, di cui 2 sono mancanti: entrambe corrispondono all'ultima settimana di rilevazione e appartengono alla stessa condizione sperimentale rispetto ad intensità e durata ($I = 90$, $D = 24$), ma con concentrazioni di fosforo diverse ($P = 1$ e $P = 25.5$). Poiché il dato mancante non è distribuito in modo uniforme sulle condizioni sperimentali, l'ipotesi di osservazioni *Missing Completely at Random* (MCAR) non è sostenibile. Le traiettorie delle due unità interessate, visualizzate in Figura 4, non mostrano anomalie fino all'ultima rilevazione disponibile, confermando che l'assenza è verosimilmente imputabile a ragioni sperimentali esterne alla dinamica biologica.

Al fine di valutare l'effetto marginale di ciascun fattore, in Figura 5 le curve sono colorate in base ai livelli di I , D e P separatamente. Si osserva un effetto apprezzabile dell'intensità luminosa I : le biomasse esposte a $I = 470$ mostrano una resa finale superiore rispetto a quelle con $I = 90$. L'effetto marginale di D e P appare meno marcato a livello visivo.

Per esaminare le possibili interazioni tra fattori, in Figura 6 si riportano i grafici delle dinamiche medie condizionate: si fissa un fattore come variabile di pannello e si colorano le curve medie per i livelli di un secondo fattore. Dall'analisi grafica emerge un'interazione tra l'intensità luminosa I e la durata dell'esposizione D : a parità di I , una durata prolungata ($D = 24$) tende ad amplificare l'effetto positivo dell'intensità elevata sulla resa finale. Dalla Figura 6b emergono anche delle prove a favore della presenza di un'interazione tra D e P .



(a) Traiettorie di OD per tutte le 53 biomasse.



(b) Curve medie per condizione.

Figura 3: Analisi delle traiettorie di crescita. A sinistra: traiettorie di OD per tutte le 53 biomasse colorate per condizione sperimentale, con evidenza dell'unità anomala mantenuta nell'analisi. A destra: curve medie per condizione con repliche in grigio sullo sfondo e bande a ± 1 errore standard della media.





Figura 4: A sinistra: traiettorie delle due unità con dato mancante all'ultima settimana, colorate per condizione sperimentale. A destra: le stesse unità (in arancione) evidenziate nel contesto di tutte le 53 curve.

Successivamente, si è analizzato il comportamento degli incrementi temporali. In Figura 7 si riportano gli incrementi assoluti $\Delta OD_t = OD_t - OD_{t-1}$ e i rapporti $\frac{OD_t}{OD_{t-1}}$, colorati per condizione sperimentale. Entrambe le rappresentazioni evidenziano un andamento decrescente nelle settimane finali: gli incrementi tendono a zero e i rapporti si avvicinano a 1, segnalando un rallentamento della crescita. Tale segnale è coerente con l'assunzione di un asintoto, sebbene l'orizzonte temporale di 8 settimane non sia sufficiente a osservare un plateau completo nelle osservazioni in scala originale; questo costituisce una limitazione del disegno che andrà considerata nella fase di modellazione.

Infine, è stata analizzata l'evoluzione della varianza dei dati di OD in funzione del tempo e della media empirica. Come mostrato nel grafico a sinistra della Figura 8, la varianza non è costante, ma aumenta in modo non lineare con il progredire del tempo. Il grafico a destra evidenzia la relazione diretta tra media e varianza calcolate per ciascun punto temporale: la varianza si configura come una funzione non lineare e crescente della media. Questo fenomeno di eteroschedasticità è coerente con la natura dei processi biologici, in cui la variabilità tende ad amplificarsi all'aumentare dell'intensità del segnale.




Figura 5: Curve di crescita colorate per livello di ciascun fattore: intensità luminosa I (sinistra), durata D (centro), concentrazione di fosforo P (destra). Le curve in grassetto rappresentano le medie per livello; le bande indicano ± 1 errore standard.

4 Le caratteristiche dei dati

Le analisi esplorative hanno evidenziato alcune criticità nella struttura dei dati, da interpretare tramite un modello.

La crescita di ciascuna biomassa ha un comportamento non lineare (Figura 3a e Figura 3b). Questo comportamento è tipico delle meccaniche di crescita in un contesto ecologico [3], ma anche per lo specifico batterio *Nostoc* [4]. Per descrivere tale evoluzione abbiamo assunto che la media della curva di crescita segua la funzione di Gompertz; questa scelta è altrettanto comune in questo contesto. Tale funzione descrive una fase iniziale di rapida espansione, seguita da un progressivo rallentamento fino al raggiungimento di un asintoto. Tale impostazione è coerente con le curve degli incrementi osservate, caratterizzate da una velocità di crescita dapprima in aumento ma che poi cala, ad indicare che si sta raggiungendo l'asintoto superiore. Inoltre, i dati osservati non evidenziano una fase di declino successiva al raggiungimento di un plateau, perciò si è scelto di non adottare modelli in grado di catturare dinamiche decrescenti. È stata considerata una conveniente riparametrizzazione della funzione di Gompertz, che viene regolata dai parametri $Asym$, b_2 , b_3 , che spiegano rispettivamente asintoto, inizio della crescita e velocità di crescita. I parametri di interesse, in particolare, risultano essere l'asintoto e la velocità di crescita.

Inoltre, misure ripetute sullo stesso soggetto nel tempo possono presentare correlazione seriale. Per tenere conto di questa possibile struttura, abbiamo valutato due opzioni: modellare la matrice di varianze e covarianze mediante un processo autoregressivo del primo ordine (AR(1)) e l'introduzione di un effetto casuale per soggetto, rispetto ai parametri di interesse.

Anche la varianza risulta essere non costante lungo tutto il processo di crescita, configurando una situazione di eteroschedasticità; in particolare, si osserva come aumenti al passare del tempo e al crescere della media della variabile risposta.

5 Il modello

La scelta del modello è motivata dall'analisi esplorativa, dall'analisi dell'adattamento delle curve stimate, dai criteri di informazione e da considerazioni biologiche. La forma parametrica adottata per μ_{ij} , la media del processo, è quindi:

$$\mu_{ij} = A_i \cdot \exp(-b_{2,i} \cdot b_{3,i}^{t_{ij}}),$$

dove $i = 1, \dots, 53$ indicizza la curva (unità sperimentale), $j = 1, \dots, n_i$ indicizza le misurazioni nel tempo, con $n_i = 6$ per $i \in \{12, 15\}$ e $n_i = 7$ per $i \in \{1, \dots, 53\} \setminus \{12, 15\}$. Infine $t_{ij} \in \{1, 2, \dots, n_i\}$ è il tempo in settimane.

Ogni parametro della Gompertz dipende da un vettore di covariate $\mathbf{x}_i$ attraverso un predittore lineare. Per garantire i vincoli biologici $A_i > 0$, $b_{2,i} > 0$, $b_{3,i} \in (0, 1)$ e assicurare la geometria corretta nello spazio dei parametri per il campionamento MCMC, si adotta la seguente riparametrizzazione:

$$\log(A_i) = \mathbf{x}_i^\top \boldsymbol{\beta}_A, \quad \log(b_{2,i}) = \mathbf{x}_i^\top \boldsymbol{\beta}_B, \quad \text{logit}(b_{3,i}) = \mathbf{x}_i^\top \boldsymbol{\beta}_C + v_i,$$

dove $v_i \sim \mathcal{N}(0, \sigma_C^2)$ è l'effetto casuale specifico della curva i .

Il vettore delle covariate $\mathbf{x}_i$ è stato esteso a ordine quadratico:

$$\mathbf{x}_i = (1, x_{I,i}, x_{D,i}, x_{P,i}, x_{I,i}x_{D,i}, x_{I,i}x_{P,i}, x_{D,i}x_{P,i}, x_{I,i}^2, x_{D,i}^2, x_{P,i}^2)^\top \in \mathbb{R}^{10}.$$




Figura 6: Dinamiche di crescita medie condizionate. Le bande indicano ± 1 errore standard della media.




Figura 7: Incrementi temporali di OD colorati per consumo $C = I \cdot D$. A sinistra: differenze assolute ΔOD ; la linea tratteggiata rossa indica il valore zero. A destra: rapporti OD_t/OD_{t-1} ; la linea tratteggiata rossa indica il valore 1. Le curve in grassetto sono le medie per livello di consumo; le bande indicano ± 1 errore standard.




Figura 8: Analisi della variabilità dei dati di OD. A sinistra: andamento della varianza in funzione del tempo. A destra: relazione tra media e varianza per ciascun punto temporale; la linea grigia tratteggiata rappresenta la relazione lineare. In entrambi i grafici, la linea rossa indica il trend non parametrico stimato mediante regressione locale LOESS (span = 1).

Questa struttura, come anticipato nella Sezione 2, è necessaria affinché la superficie ammetta un massimo interno.

Si è infine modellata la struttura di eteroschedasticità tramite una funzione power-law della media $\sigma^2 \cdot \mu_{ij}^\delta$ con $\delta \geq 0$. Il caso limite $\delta = 0$ (omoschedasticità) è compreso come caso speciale.

Il modello completo è quindi:

$$\begin{aligned} OD_{ij} &\sim \mathcal{N}(\mu_{ij}, \sigma^2 \mu_{ij}^\delta) \\ \mu_{ij} &= e^{\mathbf{x}_i^\top \beta_A} \cdot \exp\left(-e^{\mathbf{x}_i^\top \beta_B} \cdot \text{logit}^{-1}(\mathbf{x}_i^\top \beta_C + v_i)^{t_{ij}}\right) \\ v_i &\sim \mathcal{N}(0, \sigma_C^2), \quad i = 1, \dots, 53. \end{aligned}$$

6 Specificazione delle distribuzioni a priori

Tutta l'inferenza è stata condotta in un quadro bayesiano. Le distribuzioni a priori sono state scelte in modo da incorporare l'informazione biologica disponibile e garantire l'identificabilità del modello.

Le intercette dei tre predittori lineari $\beta_{A,0}$, $\beta_{B,0}$, $\beta_{C,0}$ (corrispondenti alla condizione di riferimento, il centro del disegno) ricevono prior informative ancorate ai valori biologicamente plausibili:

$$\beta_{A,0} \sim \mathcal{N}(2.1, 0.2^2), \quad \beta_{B,0} \sim \mathcal{N}(0.7, 0.5^2), \quad \beta_{C,0} \sim \mathcal{N}(0.5, 0.5^2)$$

corrispondenti, nella scala originale dei parametri, a $A = e^{2.1} \approx 8.2$, $b_2 = e^{0.7} \approx 2$ e $b_3 = \text{logit}^{-1}(0.5) \approx 0.62$.

I rimanenti 9 coefficienti di ciascun vettore (effetti principali, interazioni e termini quadratici) ricevono una prior comune regolarizzante:

$$\beta_{A,p}, \beta_{B,p}, \beta_{C,p} \sim \mathcal{N}(0, 0.25^2), \quad p = 2, \dots, 10.$$

La deviazione standard 0.25 sulla scala log corrisponde a effetti moltiplicativi entro un fattore $e^{0.5} \approx 1.65$ a $\pm 2SD$, un intervallo credibile per variazioni relative tra livelli dei fattori. Questa scelta garantisce sufficiente regolarizzazione sui termini ad alto ordine, riducendo il rischio di sovradattamento con il numero limitato di curve osservate.

Gli effetti casuali vengono campionati nella forma *non-centered*:

$$v_i = \sigma_C \cdot v_{\text{raw},i}, \quad v_{\text{raw},i} \sim \mathcal{N}(0, 1).$$

per migliorare l'efficienza del campionamento HMC con valori piccoli di σ_C .

Per i parametri relativi alla varianza sono state scelte le seguenti prior:

$$\sigma_C \sim \text{Exp}(1), \quad \sigma \sim \text{Exp}(1), \quad \delta \propto \mathcal{N}(1, 0.5^2) \cdot I(\delta > 0)$$

7 Implementazione e diagnostica

Il modello è implementato in **Stan** [5] tramite l'interfaccia R **CmdStanR** [6]. La stima è stata eseguita con 4 catene indipendenti, ciascuna con 1000 iterazioni di warmup e 2000 iterazioni di campionamento. La qualità della stima è stata valutata attraverso diagnostiche numeriche e grafiche.

Tabella 1: Riepilogo delle diagnostiche MCMC per i parametri principali.

Parametro	Media	Mediana	SD	IC _{5%}	IC _{95%}	$\hat{R}$
$\beta_{A,0}$	3.277	3.279	0.140	3.048	3.507	1.0003
$\beta_{B,0}$	1.722	1.723	0.029	1.673	1.769	1.0005
$\beta_{C,0}$	1.653	1.654	0.065	1.540	1.755	1.0006
σ_C	0.087	0.086	0.015	0.063	0.113	1.0002
σ	0.229	0.229	0.011	0.212	0.248	1.0002
δ	1.325	1.322	0.121	1.132	1.532	1.0006

Nota: i valori numerici precisi sono prodotti a runtime dal blocco di diagnostica del codice R. Le diagnostiche riportate nel testo si riferiscono ai risultati osservati durante l'esecuzione del modello.


Le diagnostiche numeriche non hanno rilevato transizioni divergenti in nessuna delle quattro catene. L'ESS_{bulk} minimo tra i parametri monitorati è pari a 1719, mentre l'ESS_{tail} minimo è pari a 3485, confermando la buona qualità del campionamento sull'intera distribuzione posteriore. Nella Tabella 1 sono riportate le statistiche riassuntive dei principali parametri del modello: i valori di $\hat{R}$ sono tutti prossimi a 1, e la sostanziale coincidenza tra media e mediana confermano la convergenza delle catene verso delle distribuzioni a posteriori simmetriche.

A livello grafico, il Rank Plot (Figura 9a) mostra distribuzioni dei ranghi uniformi e sovrapposte per tutte e quattro le catene, mentre i Trace Plot (Figura 9b) evidenziano assenza di trend sistematici o blocchi prolungati, sia per i coefficienti $\beta_{A,0}$, $\beta_{B,0}$, $\beta_{C,0}$ che per i parametri di varianza σ_C , σ , δ .

Il PPC per settimana rivela invece alcune discrepanze sistematiche: la variabilità osservata tende a cadere nella coda inferiore della distribuzione predittiva nelle prime settimane e in quella superiore nelle ultime (Figura 10a), e la mediana osservata risulta ai margini della distribuzione predittiva in alcuni punti temporali (Figura 10b). Analogamente, l'autocorrelazione a ritardo 1 dei residui per curva (Figura 11) presenta una distribuzione asimmetrica verso valori positivi e alcune curve con autocorrelazione negativa, segnalando una struttura temporale residua non completamente assorbita dal modello.

8 Interpretazione della distribuzione a posteriori


I parametri di varianza (Figura 12) mostrano distribuzioni posteriori ben identificate e concentrate. La deviazione standard dell'effetto casuale $\sigma_C = 0.086$ (mediana) è piccola ma non trascurabile sulla scala logit di b_3 , confermando che curve esposte alle stesse condizioni sperimentali presentano comunque variabilità residua nel tasso di crescita. La scala residua $\sigma = 0.229$ e l'esponente eteroschedastico $\delta = 1.325$, indicano che siamo lontani dalla condizione di omoschedasticità.



(a) Rank plot dei parametri strutturali.

(b) Trace plot dei parametri strutturali.

Figura 9: Analisi della convergenza delle catene stimate, a sinistra il rank plot, a destra il trace plot, per le tre intercette dei predittori lineari, per la varianza dell'effetto casuale e dei residui e l'esponente per la relazione di eteroschedasticità



(a) PPC della deviazione standard.

(b) PPC della mediana.

Figura 10: Posterior predictive check: deviazione standard (sinistra) e mediana (destra) degli OD per settimana. Istogrammi chiari: repliche dal modello posteriore; Linea blu: statistica osservata.

Gli effetti principali (Figura 13a) rivelano un quadro interpretativo chiaro. Il fosforo x_P e l'intensità luminosa x_I hanno entrambi un effetto positivo sull'asintoto $\log(A)$, con intervalli di credibilità al 90% chiaramente lontani dallo zero: concentrazioni più elevate di fosforo e maggiore intensità luminosa aumentano la biomassa massima raggiungibile. L'intensità luminosa agisce anche sulla velocità di crescita attraverso $\logit(b_3)$, con un effetto negativo ben identificato: valori più alti di x_I abbassano b_3 , accelerando il raggiungimento del plateau. La durata dell'esposizione x_D mostra invece effetti più incerti: una lieve tendenza negativa sull'asintoto e su $\logit(b_3)$, con intervalli di credibilità che includono lo zero, suggerendo un ruolo secondario rispetto agli altri fattori. Gli effetti su $\log(b_2)$ sono modesti e vicini allo zero per tutti e tre i fattori.

Le interazioni (Figura 13b) arricchiscono il quadro: si osserva una marcata sinergia positiva tra x_I e x_P sull'asintoto (IC 90% positivo, mediana ≈ 0.6), indicando che l'effetto della luce sulla biomassa massima si amplifica in presenza di concentrazioni elevate di fosforo. Analogamente, l'interazione $x_I \times x_D$ ha un effetto positivo sull'asintoto, mentre l'interazione $x_D \times x_P$ risulta negativa, suggerendo un effetto antagonista tra durata dell'esposizione e fosforo. I termini quadratici (Figura 13c) presentano intervalli di credibilità molto ampi che includono lo zero per tutti i fattori su tutti i parametri, indicando che la curvatura della superficie di risposta non è identificata con precisione dai dati disponibili. Nel complesso, il modello indica come la biomassa massima raggiungibile sia governata principalmente dagli effetti principali di x_I e x_P e dalla loro interazione sinergica, mentre la velocità di crescita è influenzata soprattutto dall'intensità luminosa.




Figura 11: ACF dei residui.

9 Confronto tra combinazioni osservate

Per ciascuna delle 17 combinazioni sperimentali osservate si stima la distribuzione predittiva di OD a orizzonte temporale fisso t^* , con effetto casuale pari a 0, motivato dalla scelta di prevedere il comportamento di una nuova unità sperimentale tipica [7]. Per ogni coppia di combinazioni (c_i, c_j) si stima la probabilità di superamento $P(c_i \succ c_j \mid \mathbf{y})$ e la differenza media $\Delta_{ij}(t^*)$, sintetizzate nelle heatmap di Figura 14a ($t^* = 6$) e Figura 14b ($t^* = 7$).

Il quadro che emerge è netto: le combinazioni con intensità luminosa $I = 470$ dominano tutte le altre, con probabilità di superamento prossime a 1 e differenze medie di OD comprese tra 2 e 7 unità a $t^* = 6$, che crescono fino a 10 unità a $t^* = 7$ (Figura 14b). All'interno di questo gruppo, la combinazione 470, 24, 25.5 risulta la migliore a entrambi gli orizzonti temporali, seguita da 470, 18, 25.5; tuttavia la gerarchia interna tra le combinazioni con $I = 470$ è meno certa, con probabilità di superamento, comunque elevate, comprese tra 0.80 e 0.97. È interessante notare come $P = 25.5$ (livello centrale) risulti generalmente preferibile a $P = 50$ a parità di altri fattori, e come bassi livelli di fosforo ($P = 1$) non penalizzino necessariamente la crescita quando l'intensità luminosa è elevata (470, 24, 1 si colloca nel gruppo di testa). Le combinazioni con $I = 90$ e $D = 12$ sono le peggiori in assoluto, con 90, 12, 1 che viene dominata da tutte le altre con probabilità prossima a 1. Le combinazioni con $I = 280$ occupano una fascia intermedia, con prestazioni che dipendono in modo più marcato dal livello di fosforo e dalla durata dell'esposizione. I risultati sono sostanzialmente stabili tra $t^* = 6$ e $t^* = 7$, con un ampliamento delle differenze assolute ma senza variazioni nell'ordinamento generale delle combinazioni.

10 Ottimizzazione del disegno sperimentale

Poiché la soluzione analitica del problema di ottimizzazione non è disponibile, si adotta un'enumerazione su griglia densa: $30^3 = 27,000$ punti nell'ipercubo $[-1, 1]^3$, valutati su 2000 campioni estratti dalla distribuzione posteriore. La scelta di tenere l'effetto casuale pari a 0 è coerente con quella del confronto tra combinazioni: anche qui si cerca la combinazione ottimale per un'unità sperimentale tipica, con effetto casuale marginato. L'analisi viene condotta per cinque orizzonti temporali: $t^* \in 5, 6, 7$ settimane, rientranti nell'intervallo sperimentale osservato, e $t^* \in 8, 9$, che comportano una modesta estrapolazione oltre tale intervallo e devono essere interpretati con maggiore cautela.

Il risultato più netto riguarda l'intensità luminosa: $I = 470$ in tutti i campioni posteriori e per tutti gli orizzonti temporali, senza alcuna incertezza (Figura 15). La superficie di risposta è monotona crescente in I nell'intero dominio sperimentale, e l'ottimo si colloca al bordo superiore. Per il fosforo, l'ottimo è interno al dominio: la mediana posteriore si stabilizza intorno a $P^* \approx 31$, con un intervallo di credibilità al 90% $P \approx 25-38$, sostanzialmente stabile al variare di t^* . La durata dell'esposizione x_D^* è invece la componente più incerta: per $t^* \leq 6$ la distribuzione posteriore è bimodale, con massa sia a $D = 12$ che a $D = 24$, indicando che i due estremi del dominio producono OD simili a orizzonti temporali brevi. A partire da $t^* = 7$ la distribuzione si sposta progressivamente verso $D = 24$, e a $t^* = 9$ la mediana è $D^* = 24$ con incertezza residua ridotta.

I risultati sono riassunti in Tabella 2. Per i tre orizzonti osservati, la mediana posteriore dell'OD massimo cresce da 6.0 ($t^* = 5$) a 12.8 ($t^* = 7$), con intervalli di credibilità al 90% contenuti. Per i due orizzonti estrapolati, l'OD sale ulteriormente fino a 23.6 a $t^* = 9$, ma la banda di credibilità si allarga sensibilmente ($[20.3, 28.3]$), riflettendo l'incertezza crescente della




Figura 12: Distribuzione a posteriore dei parametri di varianza.

Tabella 2: Mediana e intervallo di credibilità al 90% per l'ottimo posteriore, in unità originali, per ciascun orizzonte t^* . I valori con $\dagger$ si riferiscono a orizzonti estrapolati oltre l'intervallo sperimentale osservato (1-7 settimane).

t^*	I^*	D^* [IC 90%]	P^* [IC 90%]	$OD_{\max}$ [IC 90%]
5	470	12 [12; 24]	29.7 [24.7; 36.6]	6.0 [5.3; 7.1]
6	470	12 [12; 24]	31.4 [24.7; 36.5]	9.0 [7.9; 10.4]
7	470	21.1 [12; 24]	31.4 [26.3; 36.5]	12.8 [11.2; 14.9]
8 $\dagger$	470	23.6 [12; 24]	31.4 [26.3; 38.2]	17.7 [15.4; 20.9]
9 $\dagger$	470	24 [12; 24]	31.4 [28.0; 38.2]	23.6 [20.3; 28.3]


previsione oltre l'intervallo osservato (Figura 16). Il compromesso tra tempo di coltivazione e resa è evidente: prolungare il ciclo da 6 a 7 settimane aumenta l'OD ottimale di circa 4 unità (da ≈ 9 a ≈ 13), con un guadagno decrescente nelle settimane successive.

11 Limitazioni e sviluppi futuri


Il modello adottato presenta alcune semplificazioni che è opportuno documentare.

L'effetto casuale è stato introdotto solo su $b_{3,i}$. In linea di principio, variabilità inter-curva potrebbe essere presente anche su A_i e $b_{2,i}$; tuttavia, il modello con gli effetti casuali su tutti i parametri tende a sovra-stimare la varianza dei dati, e portare a problemi di convergenza.


L'ottimizzazione su griglia con 30 punti per lato introduce un errore di discretizzazione. Si è scelto 30 punti come compromesso adeguato per i fini dell'analisi. Uno sviluppo futuro può essere quello di aumentare i punti della griglia per una ricerca più fine dell'ottimo. Inoltre, il valore ottimo osservato si trova sulla frontiera del disegno sperimentale ($I = 470$),



(a) Distribuzione a posteriore dei parametri principali.



(b) Distribuzione a posteriore dei parametri di interazione.



(c) Distribuzione a posteriore dei parametri relativi ai termini quadratici.

per cui un futuro esperimento con aumento dell'intensità luminosa a cui è sottoposta la biomassa potrebbe portare ad un miglioramento della resa.

Infine, i valori $t^* = 8,9$ superano l'intervallo sperimentale osservato, le previsioni si basano interamente sull'assunto parametrico. Per definizione la Gompertz non modella la decrescita e garantisce che la previsione converga verso A_i . Questi risultati devono essere quindi interpretati con cautela.

12 Conclusioni


Il progetto ha voluto analizzare i dati relativi a 53 biomasse *Nostoc*, con l'obiettivo di caratterizzare la loro produzione di energia condizionatamente alle condizioni a cui sono sottoposte, con particolare attenzione alla massimizzazione di bioenergia prodotta e alla relativa velocità di produzione.

Con questo obiettivo, è stato sviluppato un modello con distribuzione Normale e con media dettata dalla funzione Gompertz, stimato tramite inferenza bayesiana, con termini quadratici nei predittori lineari, effetti casuali sul parametro di velocità di crescita ed eteroschedasticità di tipo power-law.


La scelta del modello bayesiano rispetto all'approccio frequentista è stata motivata da una corretta gestione dell'incertezza sui parametri e nelle previsioni, oltre alla possibilità di confrontare direttamente le combinazioni di condizioni sperimentali senza affrontare il problema dei test multipli.

Le diagnostiche MCMC indicano una buona capacità del modello di riprodurre le caratteristiche distribuzionali dei dati osservati, inclusa la struttura eteroschedastica. L'analisi di ottimizzazione fornisce una distribuzione a posteriori sull'ottimo (I^*, D^*, P^*) che consente di quantificare l'incertezza sulla combinazione ottimale.

I risultati del modello mostrano che la biomassa massima raggiungibile è determinata in larga parte dagli effetti di I e P e dalla loro interazione, mentre la velocità di crescita risulta governata soprattutto dall'intensità luminosa.



(a) Heatmap di confronto tra le condizioni sperimentali al tempo 6. Sopra ci sono le probabilità, sotto le differenze.



(b) Heatmap di confronto tra le condizioni sperimentali al tempo 7. Sopra ci sono le probabilità, sotto le differenze.

Per quanto riguarda l'ottimizzazione del processo, la combinazione sperimentale che massimizza la resa alla settima settimana corrisponde ai livelli $I = 470$, $D = 21.1$ e $P = 31.4$. Fissando i fattori su queste coordinate, la stima dell'intervallo di previsione Bayesiano a posteriori al 90% per OD è $[11.12, 14.9]$.




Figura 15: Curve di livello della superficie ottimizzata rispetto alle tre condizioni sperimentali, valutate al tempo 6 e al tempo 7.




Figura 16: Distribuzione dell'ottimo.

Bibliografia

- [1] Douglas C Montgomery. *Design and analysis of experiments*. John wiley & sons, 2013.
- [2] Rainer Lach et al. *DoE Application within Analytical Valve Train Development*. 2005. ISBN: 978-3816924982.
- [3] CE Timothy Paine et al. «How to fit nonlinear plant growth models and calculate growth rates: an update for ecologists». In: *Methods in Ecology and Evolution* 3.2 (2012), pp. 245–256.
- [4] Martha Lucia Ortiz-Moreno et al. «Modeling the effects of light wavelength on the growth of *Nostoc ellipsosporum*». In: *Universitas Scientiarum* 25.1 (2020), pp. 113–148.
- [5] Stan Development Team. *Stan Modeling Language User’s Guide and Reference Manual, Version 1.0*. 2012. URL: <http://mc-stan.org/>.
- [6] Stan Development Team. *RStan: the R interface to Stan*. R package version 2.32.7. 2025. URL: <https://mc-stan.org/>.
- [7] R McElreath. «Statistical rethinking: A Bayesian course with examples in R». In: *Stan R and stan, 1st ed.* Boca Raton: Chapman and Hall/CRC (2015).