

# Analisi di dati sperimentali sulla produzione di biomassa

*Modellazione bayesiana della crescita di Nostoc*

Giorgia Caicchiolo · Marco Nascimben · Riccardo Pati · Luca Varotto

9 Giugno 2026

# Introduzione e obiettivo

- Oggetto: crescita di cianobatteri Nostoc in condizioni controllate.
- Variabile risposta: Densità Ottica (OD), proxy della concentrazione di biomassa.
- Dataset: 53 biomasse monitorate per **7 settimane**, per un totale di 371 osservazioni totali.
- Ci aspettiamo una **crescita**, un successivo **rallentamento** e un'eventuale fase di **decrecita**.

## 3 fattori sperimentali controllati:

**I**

Intensità luminosa  
90 · 280 · 470

**D**

Durata esposizione  
12 · 18 · 24

**P**


Concentrazione fosforo  
1 · 25.5 · 50

**Obiettivo:** valutare come I, D, P influenzano la resa massima e la velocità di crescita

# Il disegno sperimentale (FCCCD)


*FCCCD — 17 combinazioni distinte vs. 27 del fattoriale completo*

- 8 punti ai vertici + 6 punti assiali + 1 punto centrale.
- 2 combinazioni geometriche aggiuntive.
- Punto centrale (I=280, D=18, P=25.5): 8 repliche.
- 16 altre combinazioni: 2-4 repliche ciascuna.
- Totale: 53 unità sperimentali, 371 osservazioni.
- Inserimento dei termini quadratici.




# Analisi esplorativa: Traiettorie di crescita

- Le 53 biomasse mostrano crescita non lineare con variabilità tra condizioni apprezzabile.
- 2 valori mancanti all'ultima settimana: entrambe associate a I=90, D=24.






Tutte le curve per condizione



Unità con dati mancanti (rosso)

# Analisi esplorativa: Effetti marginali dei fattori


- I (intensità luminosa): effetto più marcato → biomasse con I=470 raggiungono rese sistematicamente superiori.
- Effetto di D e P meno distinguibile visivamente. Curve medie per livello con bande =  $\pm 1$  SE.






# Analisi esplorativa: Interazioni e rallentamento della crescita

- Interazione tra I e D: a parità di I, esposizione più lunga (D=24) amplifica la resa ad alta intensità.
- Incrementi decrescenti nelle ultime settimane → rallentamento coerente con un asintoto.
- 7 settimane non sufficienti a osservare un plateau completo.



Curve medie condizionate a I, con pannelli per D



$\Delta OD$  e rapporti  $OD_t / OD_{t-1}$  per livello di consumo I x D



# Caratteristiche dei dati e scelta del modello

**Crescita non lineare:**

→ funzione di Gompertz per la media  $\mu_{ij}$ .


**Eteroschedasticità:**

→ varianza aumenta con la media: struttura power-law  $\sigma^2 \cdot \mu_{ij}^\delta$ .

**Correlazione seriale intra-curva:**

→ effetto casuale.

→ struttura di autocorrelazione.



A sinistra: andamento della varianza in funzione del tempo.  
A destra: relazione tra media e varianza per ciascun punto temporale

# Il modello di Gompertz a effetti misti

$$OD_{ij} \sim N(\mu_{ij}, \sigma^2 \cdot \mu_{ij}^\delta)$$

$$\mu_{ij} = \exp(x'_i \cdot \beta A) \cdot \exp(-\exp(x'_i \cdot \beta B) \cdot \text{logit}^{-1}(x'_i \cdot \beta C + v_i)^{t_{ij}})$$

$$v_i \sim N(0, \sigma_C^2)$$

| Parametro                               | Significato biologico                           | Vincolo           |
|-----------------------------------------|-------------------------------------------------|-------------------|
| $A_i = \exp(x' \cdot \beta A)$          | Asintoto: biomassa massima raggiungibile        | $A_i > 0$         |
| $b2_i = \exp(x' \cdot \beta B)$         | Posizione: inizio della fase di crescita rapida | $b2_i > 0$        |
| $b3_i = \sigma(x' \cdot \beta C + v_i)$ | Velocità di crescita verso il plateau           | $b3_i \in (0, 1)$ |

$$x_i = (1, I, D, P, I \cdot D, I \cdot P, D \cdot P, I^2, D^2, P^2)^T \in \mathbb{R}^{10}$$



# I vantaggi dell'approccio bayesiano

- Risolve i problemi di convergenza dell'approccio frequentista per modelli con effetto casuale
- Semplice gestione della regolarizzazione.
- Evitiamo il problema dei test multipli.
- Possiamo estendere facilmente l'inferenza alla variabile risposta.
- Coerenza nelle previsioni.
- Costo computazionale non rilevante.

# Inferenza bayesiana: prior e implementazione

## Distribuzioni a priori

**Intercette — condizione di riferimento (centro del disegno):**

- $\beta_{A0} \sim N(2.1, 0.2) \rightarrow A \approx 8.2.$
- $\beta_{B0} \sim N(0.7, 0.5^2) \rightarrow b_2 \approx 2.$
- $\beta_{C0} \sim N(0.5, 0.5^2) \rightarrow b_3 \approx 0.62.$

**Coefficienti restanti (9 per predittore):**

- $\beta \sim N(0, 0.25^2) \rightarrow$  prior regolarizzante.

**Parametri di varianza:**

- $\sigma_C, \sigma \sim \text{Exp}(1).$
- $\delta \propto N(1, 0.5^2) \cdot I(\delta > 0).$

## Implementazione

**Linguaggio:**

- Stan via CmdStanR.

**Configurazione MCMC:**


- 4 catene indipendenti.
- 1 000 iterazioni di warmup, 2 000 iterazioni di campionamento.

# Diagnostica MCMC


## Convergenza e qualità del campionamento

Nessuna transizione divergente,  $ESS_{\text{bulk}}$  min = 1 719,  $ESS_{\text{tail}}$  min = 3 485,  $\hat{R} \approx 1$  per tutti i parametri

| Parametro    | Media | SD    | IC 5% | IC 95% | $\hat{R}$ |
|--------------|-------|-------|-------|--------|-----------|
| $\beta_{A0}$ | 3.277 | 0.140 | 3.048 | 3.507  | 1.000     |
| $\beta_{B0}$ | 1.722 | 0.029 | 1.673 | 1.769  | 1.001     |
| $\beta_{C0}$ | 1.653 | 0.065 | 1.540 | 1.755  | 1.001     |
| $\sigma_C$   | 0.087 | 0.015 | 0.063 | 0.113  | 1.000     |
| $\sigma$     | 0.229 | 0.011 | 0.212 | 0.248  | 1.000     |
| $\delta$     | 1.325 | 0.121 | 1.132 | 1.532  | 1.001     |



Rank plot — distribuzioni uniformi




Trace plot — nessun trend sistematico

# Posterior predictive check e distribuzione a posteriori


- Valutazione di come il modello riproduce il comportamento in mediana e la variabilità.
- Alcune discrepanze sistematiche nella SD nelle prime/ultime settimane: struttura temporale residua.

PPC — SD per settimana



PPC deviazione standard


PPC — Mediana per settimana




PPC mediana per settimana

# Distribuzione a posteriori dei coefficienti


- I e P: effetto positivo sull'asintoto A (IC al 90% esclude lo 0).
- I: effetto negativo su  $b_3$ , valori alti di I accelerano il raggiungimento del plateau.
- Forte interazione sinergica I×P sull'asintoto (mediana  $\approx 0.6$ ).
- Termini quadratici: IC 90% ampi che includono lo zero, curvatura non identificata con precisione.



Effetti principali



Interazioni




Termini quadratici




# Confronto bayesiano tra le 17 combinazioni sperimentali

- Per ogni coppia (c<sub>i</sub>, c<sub>j</sub>) si stima P(c<sub>i</sub> > c<sub>j</sub> | y) e la differenza media di OD.
- I = 470 domina tutte le altre. Lo scenario (470, 24, 25.5) risulta il migliore a entrambi gli orizzonti temporali.
- P = 25.5 generalmente preferibile a P = 50 a parità di altri fattori.



Heatmap a t = 6 (sopra: prob. superamento, sotto: diff. media)



Heatmap a t = 7 (sopra: prob. superamento, sotto: diff. media)



# Ottimizzazione del processo: combinazione ottimale


Enumerazione su griglia  $30^3 = 27\,000$  punti.

| t*  | I*  | D* [IC 90%]   | P* [IC 90%]       | OD_max [IC 90%]   |
|-----|-----|---------------|-------------------|-------------------|
| 5   | 470 | 12 [12; 24]   | 29.7 [24.7; 36.6] | 6.0 [5.3; 7.1]    |
| 6   | 470 | 12 [12; 24]   | 31.4 [24.7; 36.5] | 9.0 [7.9; 10.4]   |
| 7   | 470 | 21.1 [12; 24] | 31.4 [26.3; 36.5] | 12.8 [11.2; 14.9] |
| 8 † | 470 | 23.6 [12; 24] | 31.4 [26.3; 38.2] | 17.7 [15.4; 20.9] |
| 9 † | 470 | 24 [12; 24]   | 31.4 [28.0; 38.2] | 23.6 [20.3; 28.3] |

† Orizzonti estrapolati - interpretare con cautela

## Risultato chiave:

- $I^* = 470$  in tutti i campioni e per tutti gli orizzonti (bordo superiore).
- $P^* \approx 31$  [IC 90%: 25–38] — ottimo interno al dominio.
- $D^*$  bimodale per  $t^* \leq 6$ , si stabilizza su 24 per  $t^* \geq 7$ .



OD ottimale per orizzonte temporale

# Conclusioni

**Modello adottato:** Modello normale con media Gompertz, eteroschedasticità, RE su  $b_3$

**Biomassa massima (asintoto A):** governata da I e P (effetto positivo) e dalla loro interazione sinergica.

**Velocità di crescita ( $b_3$ ):** governata principalmente da I (effetto negativo: alta I  $\rightarrow$  raggiungimento plateau più rapido).

**Combinazione ottimale a  $t^*=7$ :** I = 470, D = 21.1, P = 31.4  $\rightarrow$  OD  $\in$  [11.2; 14.9] (IC 90%).

**Sviluppi futuri:** I\* = 470 sul bordo  $\rightarrow$  esplorare I > 470, D\* incerta per brevi orizzonti.

**VI RINGRAZIAMO PER L'ATTENZIONE**

# Backup slide 1: Eteroschedasticità

Sono state provate altre due strutture:

- $\sigma = \exp(\alpha + \beta \cdot t)$
- $\sigma = \beta_1 \cdot \mu + \beta_2 \cdot \mu^2$

è stata scelta quella che non dava problemi di convergenza.

# Backup Slide 2: Selezione del modello

- Modello struttura eteroschedastica, senza RE.
- Modello con RE su A e struttura eteroschedastica.
- Modello con RE su A e su  $b_3$ .
- Modello con struttura AR(1) sulla matrice di varianza e covarianza.
- Modello con RE su A e struttura AR(1) sulla matrice di varianza e covarianza.